



دانشگاه صنعتی امیرکبیر
(پلی تکنیک تهران)
دانشکده ریاضی و علوم کامپیوتر

تمرین تئوری 2
درش شبکه عصبی

نگارش

تینا حسن نسب عمران (40113008)
نگار یگانه سرهنگی (40113437)

آذر ۱۴۰۴

سوال اول) چرا معمولاً نورون‌های لایه‌های آخر دارای میدان تأثیر بزرگ ترجیح داده می‌شوند؟

آیا بزرگ شدن Effective Receptive Field می‌تواند به کارایی مدل آسیب بزند؟

در شبکه‌های عصبی عمیق، به‌ویژه CNN ها، نورون‌های لایه‌های انتهایی معمولاً دارای میدان تأثیر بزرگ هستند، زیرا این ویژگی امکان ادغام اطلاعات سراسری (Global Context) را فراهم می‌کند. بسیاری از وظایف سطح بالا مانند تشخیص شیء، درک صحنه و طبقه‌بندی تصویر نیازمند ترکیب اطلاعات از نواحی مختلف ورودی هستند.

با این حال، باید میان میدان تأثیر نظری (Theoretical Receptive Field) و ERF تمایز قائل شد. مطالعات نشان داده‌اند که اگرچه TRF با افزایش عمق شبکه رشد می‌کند، اما ERF در عمل معمولاً کوچک‌تر بوده و توزیعی متمرکز و شبیه گاوسی دارد.

تلاش برای بزرگ کردن بیش‌ازحد ERF یا افزایش عمق شبکه می‌تواند اثرات منفی به همراه داشته باشد، از جمله از دست رفتن جزئیات مکانی دقیق، افزایش وابستگی‌های کاذب به زمینه (Context Overfitting)، کاهش تمرکز شبکه بر روی شیء اصلی و تضعیف تمایز میان ویژگی‌های نقاط مختلف ورودی. این پدیده‌ها در نهایت می‌توانند به افت کارایی مدل منجر شوند.

برای مثال، شبکه ممکن است وابستگی‌های کاذب به زمینه یاد بگیرد (مثلاً یاد بگیرد که "گاو" فقط در "چمنزار" وجود دارد). اگر در داده‌های تست، گاو در خیابان ظاهر شود، شبکه ممکن است شکست بخورد. همچنین اگر ERF خیلی بزرگ باشد، ممکن است تأثیر پیکسل‌های زمینه دور با پیکسل‌های شیء اصلی یکسان شود و شبکه نتواند شیء را از زمینه جدا کند.

سوال دوم) تأثیر اتصالات پس مانده و یادگیری مقابله ای بر روی بیش هموار سازی

(الف)

Residual connection یا همان skip connection روشی در شبکه‌های عصبی است که خروجی یک لایه را مستقیماً به لایه‌های بعدی اضافه می‌کند. در Residual Block، خروجی به شکل $y = F(x) + x$ تعریف می‌شود. یعنی علاوه بر خروجی محاسبات لایه $(F(x))$ ، خود ورودی (x) هم به صورت مستقیم به خروجی اضافه می‌شود. ارتباط باقی مانده باعث می‌شود که ورودی (x) بدون تغییر به لایه بعدی منتقل شود. پس اگر لایه وسطی نتونه چیزی مفید یاد بگیره، حداقل اطلاعات اصلی حفظ می‌شود. همچنین در بک‌پراپ، گرادیان باید از لایه‌های زیاد عبور کنه. اگر فقط $(F(x))$ باشه، ممکنه گرادیان خیلی کوچک بشه (vanishing gradient). اما وقتی $y = F(x) + x$ داریم، مشتق نسبت به (x) همیشه شامل $+1$ می‌شود که باعث می‌شود گرادیان هیچ‌وقت صفر نشه و راحت‌تر به عقب برگرده. بحث oversmoothing بیشتر

برای GNN ها مطرح می شود. در GNN ها هر لایه ویژگی های گره ها رو با همسایه هاش ترکیب می کنه. وقتی تعداد لایه ها زیاد بشه، چون هر گره بارها و بارها ویژگی های همسایه هاشو با خودش ترکیب می کند بعد از چندین مرحله همه گره ها اطلاعات مشابهی از کل گراف دارند و این باعث میشه بردار ویژگی همه گره ها خیلی شبیه بهم بشه و تفاوت های محلی از بین بره. به این موضوع *oversmoothing* میگویند. البته در CNN ها هم وقتی تعداد لایه های کانولوشن و *pooling* زیاد میشه، *feature map* ها کم کم جزئیات محلی خودشون رو از دست میدن و به جای اینکه تفاوت های دقیق بین بخش های مختلف تصویر حفظ بشه، همه چیز خیلی "صاف" و یکنواخت میشه.

نقش residual connection :

$$h^{(l+1)} = F(h^{(l)}) + h^{(l)}$$

یک مسیر مستقیم از ورودی به خروجی ایجاد می کنه:

این باعث حفظ اطلاعات اولیه می شود چون ورودی هر لایه مستقیماً به خروجی اضافه میشه، ویژگی های اصلی گره ها هیچ وقت کامل از بین نمی رن. این باعث میشه گره ها حتی بعد از چندین لایه هنوز تفاوت های خودشون رو حفظ کنن. در *oversmoothing*، همه ی گره ها به یک بردار مشابه میل می کنن. اما residual connection باعث میشه همیشه یک بخش از بردار اصلی باقی بمونه و جلوی همگرایی کامل رو بگیره.

(ب)

Contrastive learning یک روش *self-supervised* در یادگیری ماشین است که هدفش یادگیری نمایش داده هاست به گونه ای که نمونه های مشابه در فضای برداری به هم نزدیک شوند و نمونه های غیرمشابه از هم دور شوند در واقع در یادگیری سنتی مدل با داده های برچسب دار آموزش می بیند اما در *contrastive learning* نیازی به برچسب های زیاد نیست و مدل با مقایسه داده ها یاد می گیرد و مدل با استفاده از یک *contrastive loss* یاد می گیرد که فاصله ی مثبت ها کم و فاصله ی منفی ها زیاد باشد.

چطوری از *oversmoothing* جلوگیری میکند؟ اگر همه ی گره ها بیش از حد شبیه شوند، *contrastive loss* به مدل فشار می آورد که آن ها را از هم دور کند. این مانع همگرایی کامل ویژگی ها می شود و مدل مجبور است برای هر گره یک *embedding* خاص نگه دارد تا بتواند مثبت ها و منفی ها را درست تفکیک کند. این الزام جلوی صاف شدن بیش از حد بردارها را می گیرد. (همچنین در CNN ها این روش با تعریف *positive pairs* دو نسخه ی *augment* شده از یک تصویر و *negative pairs* تصاویر متفاوت، مدل مجبور می شود نمایش های متمایز برای هر تصویر نگه دارد. این الزام مانع این می شود که همه ی *feature map* ها روی یک بردار مشابه همگرا شوند) همچنین در بسیاری از روش های *contrastive* برای گراف، داده ها *augment* می شوند (مثلاً حذف یال یا ویژگی یا در CNN ها، مثل چرخش، تغییر رنگ یا برش تصویر باعث می شوند مدل یاد بگیرد که حتی در نسخه های تغییر یافته، هویت تصویر حفظ شود). این باعث می شود مدل یاد بگیرد که حتی در نسخه های تغییر یافته، هویت گره ها حفظ شود و *oversmoothing* کمتر شود.

سوال سوم) بررسی 4 روش برای افزایش میدان تاثیر موثر

الف) افزایش اندازهی کرنل (Kernel Size)

با افزایش اندازهی کرنل‌های کانولوشن (مثلاً از 3×3 به 7×7)، هر نورون به‌طور مستقیم به ناحیهی بزرگ‌تری از ورودی متصل می‌شود و در نتیجه TRF افزایش می‌یابد. این روش امکان ادغام اطلاعات محلی بیشتری را در هر لایه فراهم می‌کند. با این حال، افزایش اندازهی کرنل باعث رشد سریع تعداد پارامترها و هزینهی محاسباتی می‌شود و می‌تواند خطر overfitting را افزایش دهد. اگرچه ERF نیز افزایش می‌یابد، اما این افزایش معمولاً ناکارآمد و پرهزینه است.

اگرچه میدان تأثیر مؤثر (ERF) نیز بزرگ‌تر می‌شود، اما معمولاً رشد محدودی دارد و همچنان حول ناحیهی مرکزی متمرکز باقی می‌ماند (با توزیعی شبیه گاوسی)، به‌طوری که بخش زیادی از کرنل تأثیر عملی کمی دارد. بنابراین افزایش اندازهی کرنل ممکن است از نظر محاسباتی ناکارآمد باشد و بهینه‌ترین راه برای گسترش ERF نباشد.

ب) Subsampling (Pooling / Strided Convolution)

در روش‌های زیرنمونه‌برداری مانند pooling یا convolutions با stride بزرگ‌تر، اندازهی ویژگی‌ها کاهش یافته و هر نورون در لایه‌های بعدی به ناحیهی بزرگ‌تری از ورودی وابسته می‌شود، که موجب افزایش سریع TRF می‌گردد. این روش هزینهی محاسباتی را کاهش داده و تا حدی موجب افزایش مقاومت در برابر نویز می‌شود. با این حال، از دست رفتن اطلاعات مکانی دقیق می‌تواند به کاهش عملکرد در وظایف حساس به مکان منجر شود. ERF در این حالت ممکن است ناپایدار و ناهمگن شود.

ج) افزایش عمق شبکه 2_

افزایش تعداد لایه‌ها باعث می‌شود میدان تأثیر هر نورون به‌صورت تدریجی گسترش یابد و TRF رشد کند. این امر امکان استخراج ویژگی‌های سطح بالاتر و وابستگی‌های بلندبرد را فراهم می‌کند. با این حال، در عمل مشاهده می‌شود که ERF بسیار کندتر از TRF رشد می‌کند و معمولاً متمرکز باقی می‌ماند. همچنین افزایش عمق می‌تواند منجر به پدیدهی

Oversmoothing و دشواری در آموزش شود، مگر آن که از معماری‌هایی مانند Residual Connections استفاده شود.

(د) پیچش‌های اتساعی

در کانولوشن‌های اتساع‌یافته، فاصله‌ی بین عناصر کرنل افزایش می‌یابد بدون آن که تعداد پارامترها بیشتر شود، که این امر باعث افزایش مؤثر ERF می‌گردد. این روش امکان دسترسی به اطلاعات گسترده‌تر را بدون کاهش وضوح مکانی فراهم می‌کند و به‌ویژه در وظایفی مانند segmentation بسیار مؤثر است. برخلاف روش‌های دیگر، Dilated Convolutions افزایش ERF را به‌صورت کارآمدتری نسبت به TRF انجام می‌دهند. با این حال، انتخاب نامناسب نرخ اتساع می‌تواند منجر به ایجاد الگوهای ناخواسته‌ی gridding شود.

بخش امتیازی :

شبکه‌های عصبی گرافی و بیش‌هموارسازی در آن‌ها

شبکه‌ی عصبی گرافی (GNN) مستقیماً برای داده‌هایی طراحی شده است که ساختار گرافی دارند؛ یعنی داده‌هایی که از گره‌ها و یال‌ها تشکیل شده‌اند و روابط بین اجزا مهم‌تر از موقعیت آن‌هاست. در GNN هر گره یک بردار ویژگی دارد و در هر لایه با دریافت و تجمیع اطلاعات همسایه‌ها به‌روزرسانی می‌شود. این فرآیند که Message Passing نام دارد باعث می‌شود هر گره از ساختار اطراف خود آگاه شود.

برخلاف CNN که فقط روی تصاویر منظم کار می‌کند، GNN قادر است روی ساختارهای نامنظم مثل شبکه‌های اجتماعی، مولکول‌ها، جاده‌ها یا سیستم‌های توصیه‌گر کار کند. در CNN، هر پیکسل فقط از همسایه‌های مکانی خود اطلاعات می‌گیرد، اما در GNN هر گره از همسایه‌های گرافی پیام دریافت می‌کند.

در این معماری، عملکرد هر لایه سه مرحله دارد:

1. ساخت پیام: (Message Creation)

هر گره برای هر همسایه پیام تولید می‌کند. این پیام مشابه یک فیلتر کانولوشن است که ویژگی همسایه‌ها را استخراج می‌کند؛ با این تفاوت که فیلتر ثابت نیست و می‌تواند وابسته به ویژگی گره و یال باشد.

2. تجميع پیام‌ها: (Aggregation)

پیام‌های دریافتی از همسایه‌ها با عملگرهایی مثل جمع، میانگین یا attention ادغام می‌شوند. این مرحله دقیقاً نقش «کانولوشن» را در گراف ایفا می‌کند: جمع‌آوری اطلاعات محلی.

3. به‌روزرسانی گره: (Update)

گره ویژگی جدید خود را با ترکیب ویژگی قبلی و پیام تجميع‌شده می‌سازد. این مرحله شبیه مرحله nonlinear activation در CNN است.

در CNN هر پیکسل فقط از همسایه‌های نزدیک و ثابت خودش اطلاعات می‌گیرد (مثل یک شبکه منظم). اما در GNN هر گره می‌تواند از همسایه‌هایی که ساختار گراف تعیین کرده پیام بگیرد؛ یعنی همسایه‌ها ثابت نیستند و بسته به گراف تغییر می‌کنند. به‌جای فیلترهای کانولوشن در CNN، GNN با فرستادن و جمع کردن پیام بین گره‌ها الگوها را یاد می‌گیرد.

```
m_ij^(l) = Message(h_i^(l), h_j^(l), e_ij) # Message from j to i
m_i^(l) = Aggregate({m_ij^(l) : j ∈ N(i)}) # Aggregate messages
h_i^(l+1) = Update(h_i^(l), m_i^(l)) # Update node representation
```

در شبکه‌های عصبی گرافی، هر لایه ویژگی‌های هر گره را با ویژگی‌های همسایگانش انتشار می‌دهد و سپس آن‌ها را تجميع می‌کند. تکرار این فرآیند در چندین لایه باعث می‌شود ویژگی گره‌ها تحت یک روند همگن‌سازی تدریجی قرار بگیرند؛ یعنی تفاوت‌های اطلاعاتی بین گره‌ها به‌مرور کاهش پیدا کند. این پدیده همان بیش‌هموارسازی (Oversmoothing) است.

به همین دلیل، اغلب GNN های عمیق فقط ۳-۴ لایه دارند، زیرا افزایش لایه‌ها باعث افت شدید عملکرد می‌شود.

دلایل بیش‌هموارسازی در این گراف‌ها:

- از دید ریاضی، در مدل‌هایی مانند GCN، عملگر نرمال‌شده‌ی گراف نقش یک فیلتر هموارکننده لاپلاسی (Laplacian Smoother) را دارد. بنابراین با افزایش عمق شبکه، ویژگی‌ها به‌صورت تکراری تحت هموارسازی و پراکندگی قرار می‌گیرند تا جایی که نمایش گره‌ها تقریباً به یک بردار مشابه همگرا می‌شود.
- دلیل مهم دیگر این است که در GNN ها برخلاف CNN، انتشار اطلاعات محدود به همسایگی محلی ثابت نیست؛ بلکه ساختار گراف تعیین می‌کند پیام‌ها چگونه در شبکه انتشار پیدا کنند. در بسیاری از گراف‌های واقعی که قطر کمی دارند، این انتشار بسیار سریع‌تر اتفاق می‌افتد و باعث می‌شود تنها در چند لایه، ویژگی‌ها غیرقابل تفکیک شوند. در بسیاری از گراف‌های دنیای واقعی، فاصله متوسط بین گره‌ها بسیار کم است (مثلاً گراف‌های اجتماعی) که این موضوع باعث سرعت انتشار بالاتر و بیش‌هموارسازی سریع‌تر می‌شود.

- نبود محدودیت مکانی (Locality Constraint) مثل CNN یکی دیگر از دلایل رخ دادن این پدیده می‌باشد، در CNN، انتشار اطلاعات محدود به همسایه‌های ثابت و نزدیک است که به صورت کنترل‌شده و محلی می‌باشد اما در GNN، همسایگی وابسته به ساختار گراف است و ممکن است بسیار گسترده باشد که با هر لایه محدوده انتشار بزرگ‌تر می‌شود، در نتیجه سرعت از دست رفتن اطلاعات محلی خیلی بیشتر است.

شبکه‌های جهان کوچک (Small-World Networks) و ارتباط آن با بیش‌هموارسازی

شبکه‌های جهان کوچک (Small-World Networks) نوعی ساختار گرافی هستند که در آن بیشتر گره‌ها به چند همسایه‌ی نزدیک متصل‌اند اما در کنار آن تعداد کمی یال میان‌بر (shortcuts) وجود دارد که گره‌های دور دست را به هم وصل می‌کند. این ساختار باعث می‌شود شبکه هم ضریب خوشه‌بندی بالا داشته باشد (یعنی گره‌هایی که به یک گره وصل‌اند معمولاً خودشان هم به هم وصل‌اند)، و هم فاصله‌ی متوسط کوتاه بین هر دو گره داشته باشد. این پدیده اولین بار در مدل واتس-استروگاتز (1998) معرفی شد و توضیح می‌دهد که چرا بسیاری از شبکه‌های واقعی مانند شبکه‌های اجتماعی، مغز، اینترنت و شبکه‌های بیولوژیکی رفتار «جهان کوچک» دارند. در چنین شبکه‌هایی، با چند «یال کوتاه» (shortcut) بین بخش‌های دور، فاصله‌ی سراسری به شدت کاهش می‌یابد.

وجود تعداد کمی یال میان‌بر باعث می‌شود اطلاعات با سرعت بسیار بالا در سراسر گراف منتشر شود. از دید یادگیری ماشین و شبکه‌های عصبی گرافی (GNN)، این ساختار اهمیت زیادی دارد: چون پیام‌ها در Message Passing در چند لایه می‌توانند کل گراف را پوشش دهند، شبکه‌های جهان کوچک باعث افزایش سرعت انتشار ویژگی‌ها و در نتیجه تشدید پدیده‌ی بیش‌هموارسازی (Oversmoothing) می‌شوند. یعنی ویژگی گره‌ها خیلی زود به هم شبیه می‌شوند و مدل توانایی تمایز بین گره‌ها را از دست می‌دهد. بنابراین در گراف‌های Small-World استفاده از GNN‌های عمیق مناسب نیست و معمولاً از معماری‌های کم‌عمق یا تکنیک‌های جلوگیری از بیش‌هموارسازی (مثل attention، residual connections و normalization) استفاده می‌شود.